



Universidade do Minho
Escola de Engenharia
Licenciatura em Engenharia Informática

Unidade Curricular de Inteligência Artificial

Ano Letivo de 2025/2026

TaxiGreen - Grupo 14

Afonso Martins
a106931

Luis Felício
a106913

Goncalo Castro
a107337

Guilherme Costa
a107326

Janeiro, 2026

IA

Data da Receção	
Responsável	
Avaliação	
Observações	

A106931 Afonso Martins	0.75
A107337 Gonçalo Castro	-0.25
A106913 Luis Felício	-0.25
A107326 Guilherme Costa	-0.25

Tabela 1: Distribuição de pesos por elemento do grupo

TaxiGreen - Grupo 14

Afonso Martins
a106931

Luis Felício
a106913

Goncalo Castro
a107337

Guilherme Costa
a107326

Janeiro, 2026

1. Descrição do problema

1.1. Contexto

A TaxiGreen é uma empresa de táxis urbanos que enfrenta desafios crescentes na gestão de sua frota. Com a transição progressiva para mobilidade sustentável, a empresa necessita gerir simultaneamente táxis a combustão tradicional e veículos elétricos, cada um com características distintas.

1.2. Desafio Principal

Otimizar a gestão da frota mista garantindo:

- Atendimento de todos os pedidos dentro de prazos aceitáveis
- Respetivas limitações específicas de cada tipo de veículo
- Eficiência operacional e redução de custos
- Cumprimento de critérios ambientais

1.3. Restrições e Limitações

- **Veículos Elétricos:** Autonomia limitada (300-350 km), necessitam recarga em estações específicas
- **Veículos a Combustão:** Custo operacional superior, maior impacto ambiental
- **Capacidade de Passageiros:** Diferenciada entre veículos
- **Trânsito Variável:** Condições que afetam deslocação
- **Disponibilidade de Estações:** Limitadas, podem falhar

2. Formulação do Problema

2.1. Tipo de Problema

O problema do **TaxiGreen** pode ser formulado, na sua versão base, como um problema de pesquisa em espaço de estados do tipo **estado único, determinístico e totalmente observável**, num grafo ponderado.

Isto significa que:

- Existe apenas um estado real do mundo em cada instante;
- As ações têm efeitos determinísticos e previsíveis;
- O estado completo do sistema é conhecido pelo agente;
- Os custos associados às transições entre estados são conhecidos;
- O objetivo consiste em encontrar uma sequência de ações que minimize uma função de custo global.

Cada estado representa uma configuração completa do sistema, incluindo a frota de veículos, os pedidos de transporte ativos e pendentes, a localização dos veículos e as condições atuais de tráfego. A solução corresponde a uma sequência de decisões de alocação e movimentação de veículos que conduz a um estado onde todos os pedidos são satisfeitos, com custo mínimo.

Embora a implementação atual utilize este enquadramento clássico de pesquisa em grafos, o problema aproxima-se também de um **problema de planeamento em ambiente dinâmico**, uma vez que novos pedidos surgem continuamente, os custos podem variar ao longo do tempo e podem ocorrer eventos imprevistos, como congestionamentos ou falhas de estações de recarga. Nestes cenários, o sistema aproxima-se de **problemas de contingência**.

2.2. Estado

Um estado do sistema é definido como:

$$s = (V, R, L, S, T)$$

onde:

- V é o conjunto de veículos e respetivos atributos (tipo, autonomia, capacidade e estado: livre, ocupado, em recarga ou em abastecimento);
- R é o conjunto de pedidos de transporte (pendentes, ativos, concluídos ou rejeitados);
- L representa a localização atual de cada veículo no grafo da cidade;
- S representa o estado das estações de recarga e abastecimento (disponíveis, ocupadas ou inoperacionais);
- T representa as condições atuais de trânsito e outros fatores ambientais.

2.3. Estado Inicial

O estado inicial do sistema é caracterizado por:

- A frota completa de veículos posicionada nas suas localizações iniciais e com autonomia máxima;
- Um conjunto vazio de pedidos ativos;
- Todas as estações de recarga e abastecimento operacionais;
- Condições de trânsito normais e estáveis.

2.4. Teste Objetivo

Um estado é considerado objetivo quando:

- Não existem pedidos pendentes;
- Todos os pedidos foram concluídos ou corretamente rejeitados;
- O sistema se encontra numa configuração válida da frota e das estações;
- O custo global da solução é mínimo.

Formalmente, a condição de objetivo é:

$$R_{\text{pendentes}} = \{\}$$

O objetivo global consiste em:

- Minimizar o tempo total de operação;
- Minimizar os custos operacionais;
- Minimizar as emissões de CO₂;
- Minimizar a taxa de rejeição de pedidos;
- Maximizar a taxa de ocupação da frota.

2.5. Operadores (Ações Disponíveis)

1. Alocar Veículo a Pedido automaticamente

- Pré-condições:
 - Existe um veículo disponível;
 - O veículo tem autonomia suficiente ou pode deslocar-se a uma estação.
 - O Veículo está relativamente próximo ao pedido
- Efeitos:
 - O veículo passa ao estado ocupado;
 - O pedido passa ao estado em execução.

2. Mover Veículo

- Pré-condições:
 - Existe uma ligação válida no grafo entre a posição atual e o destino.
- Efeitos:
 - Atualização da posição do veículo;
 - Redução da autonomia proporcional à distância percorrida.

3. Executar Transporte

- Pré-condições:
 - Veículo alocado a um pedido;
 - Veículo localizado na origem do pedido.
- Efeitos:
 - Transporte do passageiro até ao destino;
 - Pedido marcado como concluído;
 - Atualização da posição e da autonomia do veículo.

4. Recarregar Veículo

- Pré-condições:
 - Veículo elétrico numa estação de recarga disponível;
- Efeitos:
 - Aumento parcial ou total da autonomia do veículo;
 - Estação passa temporariamente ao estado ocupada.

5. Reabastecer Veículo

- Pré-condições:
 - Veículo a combustão numa estação de abastecimento disponível.
- Efeitos:
 - Reposição da autonomia do veículo;
 - Estação passa temporariamente ao estado ocupada.

6. Aceitar ou Rejeitar Pedido

- Pré-condições:
 - Existe um novo pedido de transporte.
- Efeitos:
 - O pedido é aceite ou rejeitado de acordo com a disponibilidade de veículos e as restrições do sistema.

2.6. Custo da Solução

A função de custo integra múltiplos critérios:

$$f(\text{solucao}) = \alpha * T_{\text{resposta}} + \beta * C_{\text{operacional}} + \gamma * E_{\text{CO2}} + \delta * P_{\text{rejeicao}}$$

onde:

- T_{resposta} é o tempo médio de resposta aos pedidos (em minutos);
- $C_{\text{operacional}}$ é o custo operacional total (em euros);
- E_{CO2} representa as emissões totais de CO2 (em kg);
- P_{rejeicao} é a taxa de pedidos rejeitados;
- alpha, beta, gamma e delta são coeficientes de ponderação que ajustam a importância relativa de cada critério.

Esta formulação transforma o problema num problema de otimização multiobjetivo, convertido numa única função de custo escalar, permitindo comparar diretamente o desempenho dos diferentes algoritmos de procura utilizados no sistema TaxiGreen.

3. Representação da Cidade

3.1. Estrutura do Grafo

- **Nós:** Representam localizações na cidade
 - Zonas de recolha de passageiros
 - Estações de recarga (para elétricos)

- Postos de abastecimento (para combustão)
- Pontos de interesse (Aeroporto, Estação, Hospital, etc.)
- **Arestas:** Representam caminhos possíveis
 - Peso: Distância (km) e tempo (minutos)
 - Fator de trânsito: Multiplicador que varia ao longo do dia

3.2. Dados da Cidade de Braga

Grafo com 6 nós principais:

0: Centro Histórico (hub central)
 1: Zona Industrial (oeste)
 2: Bairro Este (residencial)
 3: Zona Comercial (comercial)
 4: Zona Residencial Oeste
 5: Zona Norte

Distâncias aproximadas:

- Centro a Zona Industrial: 5.2 km (8 min)
- Centro a Zona Comercial: 1.5 km (3 min)
- Centro a Bairro Este: 2.1 km (4 min)

4. Algoritmos de Procura implementados

4.1. Procura Não Informada

4.1.1. BFS (Breadth-First Search)

- **Descrição:** Explora nós por níveis
- **Vantagem:** Encontra caminho com menos nós
- **Desvantagem:** Sem consideração de custos
- **Caso de Uso:** Quando distância em nós é importante

4.1.2. DFS (Depth-First Search)

- **Descrição:** Explora em profundidade
- **Vantagem:** Usa pouca memória
- **Desvantagem:** Pode ser ineficiente com grafos grandes
- **Caso de Uso:** Exploração de caminhos alternativos

4.1.3. IDS (Iterative Deepening)

- **Descrição:** Combina vantagens de BFS e DFS
- **Vantagem:** Ótimo com limite de profundidade
- **Desvantagem:** Mais iterações
- **Caso de Uso:** Quando limite de profundidade é crítico

4.1.4. UCS (Uniform Cost Search)

- **Descrição:** Procura por custo uniforme
- **Vantagem:** Encontra solução com menor custo
- **Desvantagem:** Sem heurística, pode ser lento
- **Caso de Uso:** Minimização de custos operacionais

4.2. Procura Informada

4.2.1. Greedy Search

- **Descrição:** Escolhe sempre a opção com melhor heurística

- **Heurística:** Distância euclidiana ao destino
- **Vantagem:** Rápido e geralmente bom
- **Desvantagem:** Não garante solução ótima
- **Caso de Uso:** Alocação rápida de veículos

4.2.2. A* Search

- **Descrição:** Combina custo real com heurística
- **Fórmula:** $f(n) = g(n) + h(n)$
- **Vantagem:** Ótimo com heurística admissível
- **Desvantagem:** Mais caro computacionalmente
- **Caso de Uso:** Melhor qualidade de solução

4.3. Heurísticas Especializadas

4.3.1. Heurística de Autonomia

`penalidade = (1 - autonomia_atual/autonomia_max) × 100`

Prioriza veículos com mais autonomia.

4.3.2. Heurística de Custo

`custo_estimado = distancia_km × custo_operacional_veículo/km`

Minimiza custos operacionais.

4.3.3. Heurística de Tempo

`tempo_estimado = distancia_km / velocidade_média`

Reduz tempo de deslocação.

4.3.4. Heurística Ambiental

`penalidade_ambiental =`
 - 20 se exigido elétrico e é elétrico
 - 10 se preferência ambiental e é elétrico
 - 5 se preferência ambiental mas é combustão

4.3.5. Heurística Combinada

`score = 0.3×tempo + 0.3×custo + 0.2×autonomia + 0.2×ambiental`

5. Simulação Dinâmica

SimulationEngine responsável por:

1. Gerar pedidos aleatoriamente
2. Alocar veículos a pedidos
3. Simular viagens
4. Monitorar autonomia
5. Simular recarga/abastecimento
6. Atualizar métricas

5.1. Processo de Alocação

1. Novo pedido chega
2. Filtrar veículos disponíveis
3. Para cada veículo:
 - a. Calcular score heurístico
 - b. Verificar se pode alcançar destino
4. Selecionar veículo com melhor score
5. Se nenhum disponível, rejeitar pedido

5.2. Dinâmica Temporal

- Passo de simulação: 1 minuto
- Velocidade: Ajustável (0.1x a 3x)
- Duração média de viagem: 5-15 minutos
- Taxa de chegada de pedidos: 0.3/minuto

6. Métricas de Avaliação

6.1. Métricas de Serviço

Métrica	Descrição	Unidade	Ideal
Tempo Médio de Resposta	Tempo decorrido entre o pedido do cliente e o momento de pickup.	min	< 5
Taxa de Conclusão	Percentagem de pedidos atendidos com sucesso em relação ao total de pedidos.	%	> 95
Taxa de Rejeição	Percentagem de pedidos rejeitados em relação ao total de pedidos.	%	< 5
Ocupação Média	Relação entre o número médio de passageiros transportados e a capacidade total dos veículos.	%	> 70

6.2. Métricas de Eficiência

Métrica	Descrição	Unidade	Ideal
Custo Total	Soma de todos os custos operacionais associados à frota durante a simulação.	€	Minimizar
Custo por km	Relação entre o custo operacional total e a distância total percorrida.	€/km	< 0.25
Distância Vazia	Distância total percorrida pelos veículos sem passageiros.	km	Minimizar
% Distância Vazia	Percentagem da distância percorrida sem passageiros relativamente à distância total.	%	< 30

6.3. Métricas Ambientais

Métrica	Descrição	Unidade	Ideal
Emissões de CO2	Total de emissões de dióxido de carbono geradas pela frota durante a simulação.	kg	Minimizar
Taxa de Elétricos	Percentagem de veículos elétricos em operação relativamente ao total da frota.	%	> 40

CO2 por km	Relação entre as emissões totais de CO2 e a distância total percorrida.	kg/km	< 0.15
------------	---	-------	--------

7. Interface Gráfica

7.1. Componentes da UI

1. **Painel Superior:** Tempo atual da simulação
 - Exibição de tempo atual
2. **Painel Inferior:** Controlos Principais
 - Botões: Iniciar, Parar, Resetar, Relatório




Figura 1: Painel de controlo para personalizar simulação

3. **Mapa da Cidade:** Visualização do grafo
 - Nós como pontos azuis
 - Veículos com cores:
 - ▶ Verde: Ocioso
 - ▶ Vermelho: Em serviço
 - Tipos distintos: Círculo (combustão) vs Triângulo (elétrico)
4. **Configurações**
 - Seleção de algoritmo




Figura 2: Escolha de algoritmo para usar na simulação

5. Estado da Simulação

- Pedidos ativos/completados/rejeitados
- Veículos por estado
- Métricas em tempo real




Figura 3: Botão de mostrar a tabela de carros com os valores acumulados




Figura 4: Interface da solução desenvolvida

8. Resultados Obtidos

8.1. Testes Automáticos

8.1.1. Teste 1 – Dataset Pequeno (BFS)




Figura 5: Exemplo de utilização - teste com o *dataset Small* e algoritmo BFS

Neste teste, utilizando um grafo de pequena dimensão e o algoritmo BFS, os resultados mostram um desempenho muito eficiente do sistema. Todos os pedidos foram satisfeitos, sem rejeições, o que indica que a frota disponível foi suficiente para responder à procura existente. Os tempos médios de resposta e de viagem foram bastante reduzidos, refletindo a baixa complexidade do grafo e a existência de múltiplos caminhos livres ou com tráfego moderado. O BFS revelou-se adequado neste cenário, pois a prioridade em explorar primeiro os nós mais próximos permitiu encontrar rapidamente soluções viáveis, garantindo rapidez na atribuição de veículos e estabilidade no serviço. A reduzida dimensão do problema faz com que a ausência de otimização de custos ou de tempo global não tenha impacto significativo na qualidade dos resultados.

8.1.2. Teste 2 – Dataset Grande (BFS)




Figura 6: Exemplo de utilização - teste com o *dataset Large* e algoritmo BFS

No teste com o dataset de maior dimensão, o BFS continuou a garantir a satisfação de todos os pedidos, mantendo uma taxa de aceitação de 100%. No entanto, observa-se um aumento natural na duração total da simulação e na complexidade dos percursos, devido à maior dimensão do grafo e à presença de zonas com tráfego pesado. Apesar disso, o BFS mostrou-se robusto ao conseguir sempre encontrar caminhos válidos entre origem e destino. Contudo, como este algoritmo não considera custos nem heurísticas, os trajetos escolhidos nem sempre correspondem aos mais rápidos ou aos mais eficientes em termos de congestionamento. Assim, embora o BFS seja eficaz para assegurar conectividade e completude, neste cenário maior evidencia-se a sua limitação ao nível da otimização do desempenho global da frota.

8.1.3. Teste 3 – Dataset Pequeno (A*)




Figura 7: Exemplo de utilização - teste com o *dataset Small* e algoritmo A*

No cenário com o dataset pequeno, o algoritmo A* apresentou um comportamento muito eficiente, conseguindo determinar rapidamente os percursos ótimos para os veículos. Como a dimensão do grafo é reduzida e o número de alternativas de caminho é limitado, a heurística utilizada pelo A* guia eficazmente a pesquisa diretamente para o destino, evitando a exploração de nós desnecessários. Os tempos médios de resposta e de viagem mantiveram-se baixos, e todos os pedidos foram satisfeitos sem rejeições, o que confirma a eficácia do algoritmo em ambientes simples. A vantagem principal observada foi a redução do número de expansões de nós quando comparado com BFS, resultando num processo de decisão mais rápido e direcionado.

8.1.4. Teste 4 – Dataset Grande (A*)




Figura 8: Exemplo de utilização - teste com o *dataset Large* e algoritmo A*

No dataset grande, o A* demonstrou claramente a sua superioridade face a algoritmos não informados, como o BFS. Apesar da maior complexidade do grafo e do aumento do número de pedidos e caminhos possíveis, o algoritmo conseguiu manter tempos de resposta reduzidos, explorando apenas as regiões do grafo mais promissoras segundo a heurística. A pesquisa foi significativamente mais focada, evitando a expansão massiva de estados que seria típica de uma abordagem em largura. Como resultado, os percursos encontrados aproximaram-se mais dos caminhos ótimos em termos de custo e tempo, mesmo em condições de tráfego mais exigentes. Este comportamento comprova que o A* é particularmente adequado para cenários de maior escala, onde a eficiência computacional e a qualidade das soluções tornam-se fatores críticos.

8.2. Testes Manuais

Os testes manuais foram realizados através da interface gráfica do sistema, permitindo selecionar veículos, destinos e algoritmos de procura (BFS, DFS, UCS, IDS, Greedy e A*) com visualização em tempo real dos caminhos calculados.

Algoritmos ótimos (BFS, UCS, IDS e A*) garantem encontrar o caminho de menor custo. Estes quatro algoritmos retornam o mesmo caminho, confirmando que todos encontraram a solução ótima. Algoritmos não-ótimos (DFS e Greedy) podem encontrar caminhos significativamente mais longos. O DFS depende da ordem de exploração dos nós, enquanto o Greedy pode convergir para ótimos locais.

8.2.1. Teste 1 - Dataset Médio EV-001 para N-015 (IDS)




Figura 9: Exemplo de utilização - teste com o *dataset Medium* e algoritmo IDS

Este teste utiliza o veículo elétrico EV-001 no dataset médio, aplicando o algoritmo IDS (Iterative Deepening Search). O veículo parte do nó 8 com destino ao nó 15. Como algoritmo ótimo, o IDS garante encontrar o caminho de menor custo, explorando o grafo em profundidade crescente até atingir o destino.

8.2.2. Teste 2 - Dataset Médio EV-001 para N-015 (Greedy)




Figura 10: Exemplo de utilização - teste com o *dataset Medium* e algoritmo Greedy

Utilizando o mesmo veículo EV-001 e trajeto (nó 8 → nó 15) no dataset médio, este teste aplica o algoritmo Greedy. Ao contrário do IDS, o Greedy é não-ótimo e toma decisões baseadas apenas na heurística de

proximidade ao destino, sem considerar o custo acumulado. A comparação direta com o Teste 1 evidencia as diferenças na qualidade da solução: enquanto o IDS encontra o caminho ótimo, o Greedy encontra uma rotas mais longa.

8.2.3. Teste 3 - Dataset Grande TX-003 para N-016 (A*)




Figura 11: Exemplo de utilização - teste com o *dataset Large* e algoritmo A*

Este teste utiliza o veículo a combustão TX-003 no dataset grande, partindo do nó 15 para o nó 16 com o algoritmo A*. O A* combina o custo acumulado (como o UCS) com uma heurística admissível para guiar a procura de forma eficiente. Como podemos ver este teste resultou num trajeto menor quando comparado com o teste realizado com o algoritmo Greedy.

8.2.4. Teste 4 - Dataset Grande TX-003 para N-016 (Greedy)




Figura 12: Exemplo de utilização - teste com o *dataset Large* e algoritmo Greedy

Replicando o trajeto do Teste 3 (nó 15 → nó 16) com o mesmo veículo TX-003 no dataset grande, este teste aplica o algoritmo Greedy. O Greedy tende a explorar menos nós que o A*, mas sacrifica a garantia de optimalidade ao seguir apenas a heurística local, como podemos ver pela comparação dos resultados.

9. Conclusão

Neste trabalho foi desenvolvido e analisado o sistema **TaxiGreen**, um simulador inteligente para a gestão de uma frota mista de táxis, integrando veículos elétricos e a combustão, utilizando técnicas clássicas de Inteligência Artificial baseadas em procura em espaço de estados.

O problema foi formalizado de forma rigorosa como um problema de pesquisa em grafo ponderado, determinístico, totalmente observável e de otimização, permitindo a aplicação direta de estratégias de procura não informadas e informadas, nomeadamente BFS, DFS, UCS, Greedy Search e A*.

A comparação entre os algoritmos evidenciou que:

- Estratégias não informadas são úteis para análise estrutural do problema, mas pouco eficientes em cenários reais;
- A procura gulosa é rápida, mas não garante soluções ótimas;
- O algoritmo A* apresenta o melhor compromisso entre qualidade da solução e eficiência, desde que apoiado por heurísticas admissíveis e consistentes.

A introdução de múltiplas heurísticas (tempo, custo, autonomia e impacto ambiental) permitiu aproximar o sistema de um cenário realista de tomada de decisão multi-critério, refletindo os desafios de sistemas inteligentes aplicados a mobilidade urbana sustentável.

O grupo evidencia, ainda que satisfeito com o trabalho desenvolvido, as seguintes melhorias adicionais ao projeto (caso fosse para avançar com mais correções):

- Predição de procura com padrões históricos
- *Ride-sharing* para múltiplos passageiros
- Integração com dados meteorológicos
- Sistema de incentivos para elétricos
- Otimização de turnos
- Algoritmos genéticos para otimização

O sistema desenvolvido demonstra como conceitos fundamentais de IA clássica podem ser aplicados a problemas reais, dinâmicos e com impacto social, servindo simultaneamente como ferramenta pedagógica e como protótipo funcional de apoio à decisão em sistemas de transporte inteligente.